SPRAWDZENIE WIEDZY

Databricks Fundamental

Quiz ze szkolenia

Altkom Akademia
Wydanie: październik 2026

Quiz zawiera 40 pytań jednokrotnego wyboru, pogrupowanych według modułów. W każdym pytaniu wybierz jedną, najlepszą odpowiedź. Odpowiedzi sprawdzisz w quizie w aplikacji Workshop Guide (od razu, z wyjaśnieniem) albo u trenera.

MODUŁ 01

Platforma i workspace

1. Jakie są trzy główne warstwy architektury lakehouse w Databricks?

A. Przechowywanie (Delta Lake), obliczenia (klastry i SQL warehouse) oraz nadzór (Unity Catalog)

B. Bronze, silver i gold

C. Driver, executory i shuffle

D. HDFS, MapReduce i YARN

2. Do czego służy SQL warehouse?

A. To zasoby obliczeniowe zoptymalizowane pod zapytania SQL i narzędzia BI

B. To długo działający klaster all-purpose dla notebooków

C. To kontener na tabele Delta

D. To obiekt Unity Catalog do zarządzania uprawnieniami

3. Które polecenie magiczne uruchamia SQL w notebooku Python?

A. `%python`

B. `%sql`

C. `%run`

D. `%sh`

4. Czym przede wszystkim różnią się DBFS i wolumeny Unity Catalog?

A. DBFS jest szybszy przy dużych plikach

B. Wolumeny podlegają nadzorowi Unity Catalog, z kontrolą dostępu i lineage; DBFS to wycofywany system plików bez nadzoru, którego nowe workspace'y już nie oferują

C. DBFS obsługuje format Delta, a wolumeny tylko Parquet

D. Nie ma między nimi różnicy

5. Twój katalog to `retailhub_anna`. Która ścieżka odczyta plik `orders/orders_batch.json` z wolumenu `datasets` w schemacie `default`?

A. `dbfs:/mnt/datasets/orders/orders_batch.json`

B. `retailhub_anna.default.datasets.orders_batch`

C. `/Volumes/retailhub_anna/default/datasets/orders/orders_batch.json`

D. `/Workspace/retailhub_anna/datasets/orders/orders_batch.json`

6. Za co płacisz, gdy notebook działa na klasycznym klastrze?

A. Tylko za DBU; maszyny wirtualne są wliczone

B. Za DBU w Databricks oraz za maszyny wirtualne Azure, na których działa klaster

C. Tylko za maszyny wirtualne Azure; DBU nalicza się wyłącznie na serverless

D. Stałą miesięczną opłatę za workspace

7. Pipeline uruchamia się co noc jako job z harmonogramem. Który wybór compute zwykle kosztuje najmniej?

A. Klaster all-purpose włączony przez cały dzień, żeby job szybciej startował

B. Klaster all-purpose z wyłączonym auto-termination

C. Job compute albo serverless, które startują na czas uruchomienia i zatrzymują się po jego końcu

D. Największy SQL warehouse w workspace

8. Czym jest Genie Code?

A. Czatem dla użytkowników biznesowych, który odpowiada na pytania na podstawie dashboardów i Genie Agents

B. Formaterem kodu uruchamianym przy zapisie notebooka

C. Biblioteką instalowaną przez `%pip`, która generuje kod PySpark

D. Asystentem AI w notebookach i SQL Editorze, wcześniej Databricks Assistant, który pisze, wyjaśnia i poprawia kod na podstawie metadanych Unity Catalog

9. Uruchomiłeś `display(df)` w notebooku. Jak zbudować wykres słupkowy bez pisania kodu?

A. W wyniku wybrać **+**, potem **Visualization**, a następnie typ wykresu, osie i agregację

B. Zainstalować `matplotlib` przez `%pip` i narysować DataFrame

C. Wyeksportować wynik do CSV i otworzyć go w Excelu

D. Wykresy są dostępne tylko w dashboardach AI/BI, nie w notebookach

MODUŁ 02

Architektura Spark

10. Za co odpowiada driver w klastrze Spark?

A. Za przechowywanie danych na dysku jako główny węzeł magazynujący

B. Za równoległe wykonywanie pojedynczych zadań

C. Za koordynację wykonania: uruchamia kod, buduje plan i planuje zadania

D. Za kompresję danych przed wysłaniem ich do executorów

11. Czym transformacja różni się od akcji?

A. Transformacje zapisują dane, a akcje je odczytują

B. Transformacje są leniwe i zwracają nowy DataFrame, a akcje uruchamiają obliczenia

C. Transformacje istnieją tylko w SQL, a akcje tylko w Pythonie

D. Transformacje wykonują się natychmiast, a akcje są leniwe

12. Kiedy następuje shuffle?

A. Przy każdym utworzeniu nowego DataFrame'u

B. Tylko podczas zapisu do Delta Lake

C. Gdy dane trzeba rozdzielić między partycje, zwykle przy szerokich transformacjach, takich jak `groupBy` lub `join`

D. Gdy na plikach CSV użyto `inferSchema`

13. Co oznacza leniwe wykonywanie (lazy evaluation)?

A. Spark czeka na wolne miejsce na dysku przed odczytem plików

B. Spark nie wykonuje transformacji, dopóki nie zostanie wywołana akcja

C. Spark zapisuje w cache każdy DataFrame po pierwszym odczycie

D. Spark używa wolniejszego, ale dokładniejszego silnika

MODUŁ 03

ELT i ingestia

14. Jaka jest główna wada `inferSchema=True` przy dużym pliku CSV?

A. Wykryty schemat jest zawsze błędny

B. Spark czyta plik dwukrotnie: raz, aby ustalić typy, i drugi raz, aby wczytać dane

C. Obsługiwane są tylko kolumny tekstowe

D. Nie działa z Unity Catalog

15. Która metoda zwraca liczbę wartości, średnią, odchylenie standardowe, minimum i maksimum dla kolumn DataFrame'u?

A. `df.show()`

B. `df.printSchema()`

C. `df.count()`

D. `df.describe()` (`df.summary()` dodaje percentyle)

16. Czym `display(df)` różni się od `df.show()`?

A. `display()` zapisuje DataFrame do tabeli, a `show()` tylko go odczytuje

B. `show()` działa tylko w komórkach SQL

C. `display()` pokazuje w notebooku interaktywną tabelę z wykresami i Data Profile, a `show()` wypisuje zwykły tekst

D. Nie ma między nimi różnicy

17. Tryb ANSI jest włączony, co jest ustawieniem domyślnym. Co zwrócą `CAST('abc' AS INT)` i `try_cast('abc' AS INT)`?

A. `CAST` zgłosi błąd `CAST_INVALID_INPUT`, a `try_cast` zwróci `NULL`

B. Oba zwrócą `NULL`

C. Oba zwrócą `0`

D. Oba zgłoszą błąd

18. Które wywołanie zapisuje DataFrame `df` jako zarządzaną tabelę Delta `bronze.customers` w Twoim katalogu?

A. `df.createOrReplaceTempView("customers")`

B. `df.write.mode("overwrite").saveAsTable(f"{CATALOG}.bronze.customers")`

C. `display(df)`

D. `df.cache()`

19. Jak utworzyć widok tymczasowy z DataFrame'u?

A. `df.saveAsTable("view_name")`

B. `df.createOrReplaceTempView("view_name")`

C. `spark.sql("CREATE VIEW view_name")`

D. `df.registerTable("view_name")`

20. Które podejście dodaje lub zmienia kolumnę z użyciem logiki warunkowej?

A. `df.filter()`

B. `df.withColumn()` z `when()` i `otherwise()`

C. `df.groupBy()`

D. `df.dropDuplicates()`

MODUŁ 04

Delta Lake

21. Co oznacza skrót ACID?

A. Accurate, consistent, integrated, durable

B. Atomicity, consistency, isolation, durability

C. Automated, concurrent, incremental, distributed

D. Analytical, columnar, indexed, distributed

22. Czym jest dziennik transakcji Delta (`_delta_log`)?

A. Stroną Spark UI z historią zapytań

B. Katalogiem plików CSV ze zmianami na poziomie wierszy

C. Dziennikiem w formacie JSON, który zapisuje każdą zmianę tabeli Delta i umożliwia transakcje ACID oraz time travel

D. Indeksem przyspieszającym odczyt dużych tabel

23. Co robi `MERGE INTO`?

A. Tworzy pełną kopię tabeli

B. Wykonuje upsert: aktualizuje pasujące wiersze i wstawia nowe w jednej atomowej operacji

C. Łączy dwa schematy bez zapisu danych

D. Scala dwa dzienniki transakcji w jeden

24. Jak odpytać tabelę Delta w stanie sprzed siedmiu dni?

A. `SELECT * FROM t WHERE _date = date_sub(now(), 7)`

B. `SELECT * FROM t VERSION AS OF 7`

C. `SELECT * FROM t TIMESTAMP AS OF date_sub(current_timestamp(), 7)`

D. `SELECT * FROM t AT (DAYS = 7)`

25. Co robi `VACUUM`?

A. Kompaktuje małe pliki Parquet

B. Usuwa zduplikowane wiersze

C. Trwale usuwa pliki danych, do których bieżąca wersja tabeli już się nie odwołuje i które są starsze niż okres retencji

D. Odbudowuje dziennik transakcji

26. Godzinę temu ktoś wykonał `DELETE` na niewłaściwych wierszach. Które polecenie przywróci tabelę do stanu sprzed tego `DELETE`?

A. `ROLLBACK TABLE t`

B. `UNDROP TABLE t`

C. `VACUUM t RETAIN 0 HOURS`

D. `RESTORE TABLE t TO VERSION AS OF n`, gdzie `n` to wersja sprzed `DELETE`

27. Dopisujesz do istniejącej tabeli Delta DataFrame z jedną dodatkową kolumną, bez żadnych opcji zapisu. Co się stanie?

A. Dodatkowa kolumna zostanie pominięta bez komunikatu

B. Kolumna zostanie automatycznie dodana do tabeli

C. Zapis zakończy się błędem, bo schemat się nie zgadza (schema enforcement); opcja `mergeSchema` świadomie dodaje kolumnę

D. Tabela zostanie przekonwertowana do Parquet

28. Co Databricks zaleca jako układ danych dla nowych tabel zamiast partycjonowania i `ZORDER`?

A. Liquid clustering (`CLUSTER BY` albo `CLUSTER BY AUTO`); na tabelach zarządzanych Unity Catalog predictive optimization dodatkowo sam uruchamia utrzymanie, takie jak `OPTIMIZE` i `VACUUM`

B. Partycjonowanie po każdej kolumnie używanej w filtrach

C. Zapis tabeli jako CSV

D. Cache tabeli na każdym klastrze

MODUŁ 05

Orkiestracja w Lakeflow Jobs

29. Co robi repair run?

A. Resetuje wszystkie zadania i uruchamia cały job od nowa

B. Uruchamia ponownie tylko zadania zakończone błędem i zadania od nich zależne

C. Wysyła alert i anuluje uruchomienie

D. Wycofuje zmiany w tabelach Delta wprowadzone przez nieudane uruchomienie

30. Które wyrażenie cron w formacie Quartz uruchamia job codziennie o 02:30?

A. `30 2 * * *`

B. `2 30 * * *`

C. `0 30 2 * * ?`

D. `30 2 0 * * ?`

31. Parametr joba i parametr zadania notebookowego mają ten sam klucz. Którą wartość odczyta notebook?

A. Parametr zadania

B. Ten parametr, który utworzono później

C. Żadną; uruchomienie zakończy się błędem konfliktu

D. Parametr joba, który ma pierwszeństwo

32. Który mechanizm przekazuje parametry do notebooka uruchamianego w jobie?

A. Polecenie magiczne `%run`

B. Widgety (`dbutils.widgets`)

C. Parametry Unity Catalog

D. Wyłącznie zmienne środowiskowe klastra

33. Zadanie `validate` publikuje wartość przez `dbutils.jobs.taskValues.set(key="row_count", value=n)`. Jak odczyta ją kolejne zadanie?

A. `dbutils.widgets.get("row_count")`

B. `spark.conf.get("row_count")`

C. `dbutils.jobs.taskValues.get(taskKey="validate", key="row_count")`

D. `%run ./validate`

MODUŁ 06

Unity Catalog

34. Jak wygląda trzypoziomowa przestrzeń nazw w Unity Catalog?

A. `workspace.schema.table`

B. `catalog.database.file`

C. `catalog.schema.table`, gdzie ostatnim poziomem może być też widok, wolumen lub funkcja

D. `metastore.catalog.schema`

35. Jak trzeba nadać uprawnienia, aby użytkownik uzyskał dostęp do tabeli?

A. Tylko na tabeli; wyższe poziomy nie są potrzebne

B. Tylko na poziomie metastore

C. Od góry: `USE CATALOG`, potem `USE SCHEMA`, a na końcu uprawnienie do tabeli

D. Na klastrze, przez role IAM

36. Które polecenie pokaże, kto ma jakie uprawnienia do schematu `gold` w Twoim katalogu?

A. `SHOW GRANTS ON SCHEMA my_catalog.gold`

B. `DESCRIBE SCHEMA my_catalog.gold`

C. `SHOW TABLES IN my_catalog.gold`

D. `LIST PRIVILEGES my_catalog.gold`

37. Którym grupom można nadać uprawnienia do obiektów Unity Catalog?

A. Grupom lokalnym workspace, utworzonym poleceniem SQL `CREATE GROUP`

B. Grupom kontowym, tworzonym w konsoli konta lub w ustawieniach workspace w sekcji Identity and access

C. Systemowej grupie workspace `users`

D. Każdej grupie istniejącej w workspace

38. Uczestnik ma `ALL PRIVILEGES` na katalogu, którego właścicielem jest trener, ale jego polecenie `GRANT SELECT ... TO` grupie kończy się błędem. Dlaczego?

A. `GRANT` można wykonać tylko z SQL warehouse

B. `ALL PRIVILEGES` trzeba najpierw nadać na poziomie metastore

C. `ALL PRIVILEGES` nie obejmuje `MANAGE`; uprawnienia może nadawać tylko właściciel, administrator metastore lub posiadacz `MANAGE`

D. Grupy mogą otrzymywać uprawnienia tylko do tabel

MODUŁ 07

Genie Agents, demo opcjonalne

39. Czym jest Genie Agent (wcześniej Genie space)?

A. Klastrem GPU dla modeli uczenia maszynowego

B. Interfejsem w języku naturalnym, skonfigurowanym na wybranych tabelach Unity Catalog, który odpowiada na pytania o dane za pomocą wygenerowanego SQL

C. Wspólnym obszarem do edycji notebooków

D. Dashboardem do monitorowania stanu pipeline'ów

40. Kiedy Genie Agent nie jest właściwym narzędziem?

A. Gdy użytkownik biznesowy chce eksplorować dane bez pisania SQL

B. Gdy potrzebny jest raport o ściśle określonym formacie z zatwierdzonymi KPI

C. Gdy analityk chce zadawać doraźne pytania o sprzedaż

D. Gdy chcesz sprawdzić trend przed spotkaniem