

SPRAWDZENIE WIEDZY

Databricks Fundamental

Quiz ze szkolenia z kluczem odpowiedzi

Quiz zawiera 40 pytań jednokrotnego wyboru, pogrupowanych według modułów. W każdym pytaniu wybierz jedną, najlepszą odpowiedź. Klucz odpowiedzi znajduje się na ostatniej stronie.

MODUŁ 01

Platforma i workspace

1. Jakie są trzy główne warstwy architektury lakehouse w Databricks?
 - A. Przechowywanie (Delta Lake), obliczenia (klastry i SQL warehouse) oraz nadzór (Unity Catalog)
 - B. Bronze, silver i gold
 - C. Driver, executory i shuffle
 - D. HDFS, MapReduce i YARN
2. Do czego służy SQL warehouse?
 - A. To zasoby obliczeniowe zoptymalizowane pod zapytania SQL i narzędzia BI
 - B. To długo działający klaster all-purpose dla notebooków
 - C. To kontener na tabele Delta
 - D. To obiekt Unity Catalog do zarządzania uprawnieniami
3. Które polecenie magiczne uruchamia SQL w notebooku Python?
 - A. `%python`
 - B. `%sql`
 - C. `%run`
 - D. `%sh`
4. Czym przede wszystkim różnią się DBFS i wolumeny Unity Catalog?
 - A. DBFS jest szybszy przy dużych plikach
 - B. Wolumeny podlegają nadzorowi Unity Catalog, z kontrolą dostępu i lineage; DBFS to wycofywany system plików bez nadzoru, którego nowe workspace'y już nie oferują
 - C. DBFS obsługuje format Delta, a wolumeny tylko Parquet
 - D. Nie ma między nimi różnicy
5. Które polecenie tworzy widget z listą rozwijaną?
 - A. `dbutils.widgets.text()`
 - B. `dbutils.widgets.dropdown()`
 - C. `dbutils.widgets.choice()`
 - D. `dbutils.widgets.select()`

MODUŁ 02

Architektura Spark

6. Za co odpowiada driver w klastrze Spark?

- A. Za przechowywanie danych na dysku jako główny węzeł magazynujący
- B. Za równoległe wykonywanie pojedynczych zadań
- C. Za koordynację wykonania: uruchamia kod, buduje DAG i planuje zadania
- D. Za kompresję danych przed wysłaniem ich do executorów

7. Czym transformacja różni się od akcji?

- A. Transformacje zapisują dane, a akcje je odczytują
- B. Transformacje są leniwe i zwracają nowy DataFrame, a akcje uruchamiają obliczenia
- C. Transformacje istnieją tylko w SQL, a akcje tylko w Pythonie
- D. Transformacje wykonują się natychmiast, a akcje są leniwe

8. Co robi adaptive query execution (AQE)?

- A. To ręczny proces strojenia wykonywany przez administratora
- B. Ładuje dane do pamięci przed rozpoczęciem zapytania
- C. Dostosowuje plan wykonania w trakcie działania na podstawie rzeczywistych statystyk
- D. Konwertuje kod PySpark na SQL

9. Kiedy następuje shuffle?

- A. Przy każdym utworzeniu nowego DataFrame'u
- B. Tylko podczas zapisu do Delta Lake
- C. Gdy dane trzeba rozdzielić między partycje, zwykle przy szerokich transformacjach, takich jak `groupBy` lub `join`
- D. Gdy na plikach CSV użyto `inferSchema`

10. Co oznacza leniwe wykonywanie (lazy evaluation)?

- A. Spark czeka na wolne miejsce na dysku przed odczytem plików
- B. Spark nie wykonuje transformacji, dopóki nie zostanie wywołana akcja
- C. Spark zapisuje w cache każdy DataFrame po pierwszym odczycie
- D. Spark używa wolniejszego, ale dokładniejszego silnika

MODUŁ 03

ELT i ingestia

11. Jaka jest główna wada `inferSchema=True` przy dużym pliku CSV?
- A. Wykryty schemat jest zawsze błędny
 - B. Spark czyta plik dwukrotnie: raz, aby ustalić typy, i drugi raz, aby wczytać dane
 - C. Obsługiwane są tylko kolumny tekstowe
 - D. Nie działa z Unity Catalog
12. Co robi funkcja `explode()`?
- A. Dzieli kolumnę tekstową według separatora
 - B. Zgłasza błąd przy wartościach null
 - C. Zamienia każdy element kolumny tablicowej w osobny wiersz
 - D. Rozbija strukturę na osobne kolumny
13. Który join zwraca wszystkie wiersze z lewej tabeli i tylko pasujące wiersze z prawej?
- A. `INNER JOIN`
 - B. `LEFT JOIN`
 - C. `RIGHT JOIN`
 - D. `FULL OUTER JOIN`
14. Jak utworzyć widok tymczasowy z `DataFrame`'u?
- A. `df.saveAsTable("view_name")`
 - B. `df.createOrReplaceTempView("view_name")`
 - C. `spark.sql("CREATE VIEW view_name")`
 - D. `df.registerTable("view_name")`
15. Do czego służy schemat adresu `abfss://` w Azure Databricks?
- A. Do odczytu publicznych bucketów Amazon S3
 - B. Do łączenia z Azure SQL Database
 - C. Do dostępu do Azure Data Lake Storage Gen2 przez sterownik Azure Blob File System
 - D. Do pobierania pakietów z PyPI
16. Które podejście dodaje lub zmienia kolumnę z użyciem logiki warunkowej?
- A. `df.filter()`
 - B. `df.withColumn()` z `when()` i `otherwise()`
 - C. `df.groupBy()`
 - D. `df.dropDuplicates()`

MODUŁ 04

Delta Lake

17. Co oznacza skrót ACID?

- A. Accurate, consistent, integrated, durable
- B. Atomicity, consistency, isolation, durability
- C. Automated, concurrent, incremental, distributed
- D. Analytical, columnar, indexed, distributed

18. Czym jest dziennik transakcji Delta (`_delta_log`)?

- A. Stroną Spark UI z historią zapytań
- B. Katalogiem plików CSV ze zmianami na poziomie wierszy
- C. Dziennikiem w formacie JSON, który zapisuje każdą zmianę tabeli Delta i umożliwia transakcje ACID oraz time travel
- D. Indekssem przyspieszającym odczyt dużych tabel

19. Co robi `MERGE INTO`?

- A. Tworzy pełną kopię tabeli
- B. Wykonuje upsert: aktualizuje pasujące wiersze i wstawia nowe w jednej atomowej operacji
- C. Łączy dwa schematy bez zapisu danych
- D. Scala dwa dzienniki transakcji w jeden

20. Jak odpytać tabelę Delta w stanie sprzed siedmiu dni?

- A. `SELECT * FROM t WHERE _date = date_sub(now(), 7)`
- B. `SELECT * FROM t VERSION AS OF 7`
- C. `SELECT * FROM t TIMESTAMP AS OF date_sub(current_timestamp(), 7)`
- D. `SELECT * FROM t AT (DAYS = 7)`

21. Co robi `VACUUM`?

- A. Kompaktuje małe pliki Parquet
- B. Usuwa zduplikowane wiersze
- C. Trwale usuwa pliki danych, do których dziennik transakcji już się nie odwołuje
- D. Odbudowuje dziennik transakcji

22. Jaki jest domyślny okres retencji dla `VACUUM`?

- A. 24 godziny
- B. 7 dni
- C. 30 dni
- D. 90 dni

23. Czym różnią się tabele Delta zarządzane i zewnętrzne?

- A. Tabele zarządzane używają Parquet, a zewnętrzne Delta
- B. W tabeli zarządzanej Unity Catalog kontroluje metadane i pliki danych, a w zewnętrznej tylko metadane, więc `DROP TABLE` pozostawia pliki na miejscu
- C. Tylko tabele zewnętrzne obsługują transakcje ACID
- D. Działają identycznie

24. Co daje `OPTIMIZE ... ZORDER BY`?

- A. Sortuje tabelę alfabetycznie do jednego dużego pliku
- B. Kompaktuje małe pliki i umieszcza powiązane wartości w tych samych plikach, co przyspiesza filtrowanie po tych kolumnach
- C. Usuwa duplikaty i przebudowuje statystyki
- D. Konwertuje tabelę Parquet do formatu Delta

MODUŁ 05

Orkestracja w Lakeflow Jobs

25. Co robi repair run?

- A. Resetuje wszystkie zadania i uruchamia cały job od nowa
- B. Uruchamia ponownie tylko zadania zakończone błędem i zadania od nich zależne
- C. Wysyła alert i anuluje uruchomienie
- D. Wycofuje zmiany w tabelach Delta wprowadzone przez nieudane uruchomienie

26. Które wyrażenie cron w formacie Quartz uruchamia job codziennie o 02:30?

- A. `30 2 * * *`
- B. `2 30 * * *`
- C. `0 30 2 * * ?`
- D. `30 2 0 * * ?`

27. Czym jest wyzwalacz file arrival?

- A. Wyzwalaczem uruchamianym, gdy komórka notebooka zgłosi wyjątek
- B. Wyzwalaczem uruchamianym, gdy we wskazanej lokalizacji pojawią się nowe pliki
- C. Wyzwalaczem śledzącym liczbę wierszy tabeli Delta
- D. Wyzwalaczem opartym wyłącznie na powiadomieniach Azure Event Grid

28. Czym w Lakeflow Pipelines streaming table różni się od materialized view?

- A. Streaming table można zdefiniować tylko w Pythonie, a materialized view tylko w SQL
- B. Streaming table przetwarza tylko dane wejściowe nowe od ostatniej aktualizacji, a materialized view utrzymuje aktualny, zapisany wynik zapytania
- C. Tylko materialized view obsługuje transakcje ACID
- D. Nie ma między nimi różnicy funkcjonalnej

29. Który mechanizm przekazuje parametry do notebooka uruchamianego w jobie?
- A. Polecenie magiczne `%run`
 - B. Widżety (`dbutils.widgets`)
 - C. Parametry Unity Catalog
 - D. Wyłącznie zmienne środowiskowe klastra
30. Do czego służy tabela `system.lakeflow.job_run_timeline`?
- A. Do przechowywania kodu notebooków z historią wersji
 - B. Do rejestrowania uruchomień i zatrzymań klastrów
 - C. Do monitorowania uruchomień jobów i zadań (czasu trwania, stanów i błędów) za pomocą SQL
 - D. Do wyświetlania aktywnych połączeń z SQL warehouse

MODUŁ 06

Unity Catalog

31. Jak wygląda trzypoziomowa przestrzeń nazw w Unity Catalog?
- A. `workspace.schema.table`
 - B. `catalog.database.file`
 - C. `catalog.schema.table`, gdzie ostatnim poziomem może być też widok, wolumen lub funkcja
 - D. `metastore.catalog.schema`
32. Jak trzeba nadać uprawnienia, aby użytkownik uzyskał dostęp do tabeli?
- A. Tylko na tabeli; wyższe poziomy nie są potrzebne
 - B. Tylko na poziomie metastore
 - C. Od góry: `USE CATALOG`, potem `USE SCHEMA`, a na końcu uprawnienie do tabeli
 - D. Na klastrze, przez role IAM
33. Czym jest storage credential?
- A. Sekretem przechowywanym w key vault
 - B. Obiektem Unity Catalog z długoterminową tożsamością w chmurze, na przykład Access Connectorem, używaną do uwierzytelniania w zewnętrznym magazynie
 - C. Zaszyfrowanym hasłem do zewnętrznych baz danych
 - D. Ciągłem połączenia JDBC zapisanym jako właściwość katalogu
34. Którym grupom można nadać uprawnienia do obiektów Unity Catalog?
- A. Grupom lokalnym workspace, utworzonym poleceniem SQL `CREATE GROUP`
 - B. Grupom kontowym, tworzonym w konsoli konta lub w ustawieniach workspace w sekcji Identity and access
 - C. Systemowej grupie workspace `users`
 - D. Każdej grupie istniejącej w workspace

35. Uczestnik ma ALL PRIVILEGES na katalogu, którego właścicielem jest trener, ale jego polecenie GRANT SELECT ... TO grupie kończy się błędem. Dlaczego?
- A. GRANT można wykonać tylko z SQL warehouse
 - B. ALL PRIVILEGES trzeba najpierw nadać na poziomie metastore
 - C. ALL PRIVILEGES nie obejmuje MANAGE; uprawnienia może nadawać tylko właściciel, administrator metastore lub posiadacz MANAGE
 - D. Grupy mogą otrzymywać uprawnienia tylko do tabel

MODUŁ 07

Dashboardy AI/BI i Genie

36. Czym jest przestrzeń Genie?
- A. Klastrem GPU dla modeli uczenia maszynowego
 - B. Interfejsem, w którym użytkownicy zadają pytania o dane językiem naturalnym i otrzymują odpowiedzi oparte na wygenerowanym SQL
 - C. Wspólnym obszarem do edycji notebooków
 - D. Dashboardem do monitorowania stanu pipeline'ów
37. Z jakich danych korzysta przestrzeń Genie, odpowiadając na pytania?
- A. Z dowolnej ścieżki podanej przy konfiguracji
 - B. Z indeksu Vector Search
 - C. Z tabel i widoków Unity Catalog skonfigurowanych dla tej przestrzeni
 - D. Z bieżącego połączenia z zewnętrzną bazą PostgreSQL
38. Jak udostępnić opublikowany dashboard AI/BI osobie, która nie jest członkiem Twojego workspace?
- A. Wyeksportować go do PDF; nie ma innej możliwości
 - B. Udostępnić go jej jako użytkownikowi konta Databricks; osoba ta loguje się kontem organizacyjnym Microsoft Entra ID
 - C. Skopiować dashboard do jej workspace
 - D. Dashboardów nie można udostępniać poza workspace
39. Jakie wizualizacje są dostępne w dashboardach AI/BI?
- A. Tylko wykresy punktowe 3D
 - B. Tylko diagramy Sankeya
 - C. Wykresy słupkowe, liniowe i kołowe, liczniki oraz tabele
 - D. Tylko tabele
40. Kiedy Genie nie jest właściwym narzędziem?
- A. Gdy użytkownik biznesowy chce eksplorować dane bez pisania SQL
 - B. Gdy potrzebny jest raport o ściśle określonym formacie z zatwierdzonymi KPI
 - C. Gdy analityk chce zadawać doraźne pytania o sprzedaż
 - D. Gdy chcesz sprawdzić trend przed spotkaniem

Klucz odpowiedzi

Moduł	Odpowiedzi
Moduł 01	1 A, 2 A, 3 B, 4 B, 5 B
Moduł 02	6 C, 7 B, 8 C, 9 C, 10 B
Moduł 03	11 B, 12 C, 13 B, 14 B, 15 C, 16 B
Moduł 04	17 B, 18 C, 19 B, 20 C, 21 C, 22 B, 23 B, 24 B
Moduł 05	25 B, 26 C, 27 B, 28 B, 29 B, 30 C
Moduł 06	31 C, 32 C, 33 B, 34 B, 35 C
Moduł 07	36 B, 37 C, 38 B, 39 C, 40 B

Pytania odzwierciedlają stan platformy na wrzesień 2026 r. Pytania dotyczące DBFS opisują środowisko legacy, które nadal można spotkać w istniejących workspace'ach: DBFS root i mounty nie są dostępne w kontach utworzonych po 18 grudnia 2025 r. ani w żadnym workspace utworzonym po 30 września 2026 r. Przestrzenie Genie (pytania od 36 do 40) to inna funkcja niż Genie Code, asystent w notebookach znany wcześniej jako Databricks Assistant.